TUGAS AKHIR

IMPLEMENTASI REINFORCEMENT LEARNING (Q-LEARNING) UNTUK KONTROL STABILITAS PH DAN EC PADA SISTEM HIDROPONIK

14S22036 **SAMUEL P.**

PROGRAM STUDI SARJANA TEKNIK ELEKTRO

FAKULTAS INFORMATIKA DAN TEKNIK ELEKTRO

INSTITUT TEKNOLOGI DEL

2025

TUGAS AKHIR

IMPLEMENTASI REINFORCEMENT LEARNING (Q-LEARNING) UNTUK KONTROL STABILITAS PH DAN EC PADA SISTEM HIDROPONIK

Diajukan sebagai salah satu syarat untuk memperoleh gelar
Sarjana Teknik (S.T)

14S22036 **SAMUEL P.**

PROGRAM STUDI SARJANA TEKNIK ELEKTRO

FAKULTAS INFORMATIKA DAN TEKNIK ELEKTRO

INSTITUT TEKNOLOGI DEL

2025

HALAMAN PERNYATAAN ORISINALITAS

Tugas Akhir ini adalah karya saya sendiri dan semua sumber baik yang dikutip maupun dirujuk telah saya nyatakan dengan benar.

Nama	: SAMUEL P.
NIM	: 14S22036
Tanda Tangan	:

Tanggal

HALAMAN PENGESAHAN

Tugas Akhir ini diajukan oleh :

Nama	:	SAMUEL P.
NIM	:	14S22036
Program Studi	:	Sarja Teknik Elektro
Judul Tugas Akhir	:	IMPLEMENTASI REINFORCEMENT LEARNING (Q-LEARNING) UNTUK KONTROL STABILITAS PH DAN EC PADA SISTEM HIDROPONIK.

Telah berhasil dipertanggungjawabkan di hadapan Dewan penguji dan diterima sebagai bagian persyaratan yang di perlukan untuk memperoleh gelar Sarjana Teknik (S.T) pada program studi Sarjana Teknik Elektro, Fakultas Informatika dan Teknik Elektro, Institut Teknologi Del.

DEWAN PENGUJI

Pembimbing 1	:	Albert Sagala, S.T, M.T	( )
Penguji 1	:	Good Fried Panggabean, S.T, MT, Ph.D	( )
Penguji 2	:	Andi Ray Hutauruk, S.T.,M.T.	( )

Ditetapkan	:	Laguboti
Tanggal	:	

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS

Sebagai civitas akademik Institut Teknologi Del, saya yang bertanda tangan di bawah ini:

Demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Institut Teknologi Del **Hak Bebas Royalti Non ekslusif (Non-exclusive Royalty Free Right)** atas karya ilmiah saya yang berjudul :

IMPLEMENTASI REINFORCEMENT LEARNING (Q-LEARNING) UNTUK KONTROL STABILITAS PH DAN EC PADA SISTEM HIDROPONIK.

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Nonekslusif ini Institut Teknologi Del berhak menyimpan, mengalih/media format dalam bentuk pangkalan data (database), merawat, dan mempublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta. Demikian pernyataan ini saya buat dengan sebenarnya.

Ditetapkan	:	Laguboti
Tanggal	:	

Yang menyatakan

SAMUEL P.

ABSTRAK

Nama	:	SAMUEL P.
NIM	:	14S22036
Program Studi	:	S1 Teknik Elektro
Judul Tugas Akhir	:	IMPLEMENTASI REINFORCEMENT LEARNING (Q-LEARNING) UNTUK KONTROL STABILITAS PH DAN EC PADA SISTEM HIDROPONIK.

ABSTRACT

Name	:	*SAMUEL P.*
NIM	:	*14S22036*
Program Studi	:	*S1 Teknik Elektro*
Judul Tugas Akhir	:	*IMPLEMENTATION OF REINFORCEMENT LEARNING (Q-LEARNING) FOR PH AND EC STABILITY CONTROL IN HYDROPONIC SYSTEMS.*

DAFTAR ISI

HALAMAN PERNYATAAN ORISINALITAS iii
HALAMAN PENGESAHAN iv
HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS v
ABSTRAK vi
ABSTRACT vii
DAFTAR ISI viii
DAFTAR GAMBAR x
DAFTAR TABEL xi
DAFTAR SINGKATAN xii
BAB I PENDAHULUAN 1
1.1. Latar Belakang 1
1.2. Rumusan Masalah 3
1.3. Tujuan 4
1.4. Manfaat Penelitian 4
1.5. Batasan Masalah 5
1.6. Sistematika Penulisan 5
BAB II LANDASAN TEORI 7
2.1 Sistem Hidroponik dan Dinamika Nutrisi 7
2.1.1 Definisi dan Prinsip Kerja 7
2.1.2 pH (Derajat Keasaman) 7
2.1.3 Electrical Conductivity (EC) 8
2.1.4 Interaksi pH dan EC sebagai Sistem Multivariabel 9
2.2 Penelitian Terkait 9
2.2.1 Finite State Machine 9
2.2.2 PID (Propotional-Integral-Derivative) 10
2.2.3 Fuzzy Logic Controller (FLC) 11
2.2.4 Research Gap 11
2.2.5 Solusi Reinforcement Learning (Q-Learning). 12
2.3 Reinforcement Learning dan Algoritma Q-Learning 13
2.3.1 Konsep Dasar Reinforcement Learning (RL) 13
2.3.2 Algoritma Q-Learning. 15
2.4 Arsitektur Sitem Kendali Terdistribusi 16
2.4.1 Lapisan Persepsi dan Pengambilan Keputusan 17

2.4.2 Protokol Komunikasi Data 17
2.4.3 Mekanisme Keamanan (Safety Interlock) 18
2.5 Parameter Evaluasi Performasi Kontrol 18
2.5.1 Karakteristik Respon Transien 18
2.5.2 Konvergensi Agen Pembelajaran 19
BAB III METODOLOGI PENELITIAN 20
3.1 Alur Penelitian 20
3.2 Perancangan Arsitektur Sistem 21
3.3 Perancangan Hardware 23
3.4 Perancangan Agen Cerdas 24
3.4.1 Definisi Ruang Keadaan (State-Space) 25
3.4.2 Definisi Ruang Aksi (Action-Space) 28
3.4.3 Struktur Tabel Pengetahuan (Q-Table) 29
3.4.4 Perancangan Fungsi Hadiah (Reward Function) 30
3.4.5 Logika Algoritma dan Eksekusi Aksi 33
3.5 Skenario Pengujian 37
BAB IV 38
BAB V 38
Daftar Referensi 39

DAFTAR GAMBAR

Gambar 2. 1 Ilustrasi Interaksi Agen dan Lingkungan dalam Reinforcement Learning ... 14

Gambar 3. 1 Diagram Alir Tahapan Penelitian 20

Gambar 3.2 Diagram Blok Arsitektur Sistem Kendali Terdistribusi. 22

Gambar 3.3 Diagram Alir Logika Agen Q-Learning..... 33

DAFTAR TABEL

Tabel 3.1 Aturan Diskritisasi Parameter pH.....26

Tabel 3. 2 Aturan Diskritisasi Parameter EC.....26

Tabel 3. 3 Matrik Pemetaan Ruang Keadaan (State Mapping Matrix) 27

Tabel 3. 4 Definisi Ruang Aksi dan Durasi Dosing 29

Tabel 3.5 Struktur Matriks Q-Table (25 × 9) 30

Tabel 3.6 Distribusi Nilai Reward Berdasarkan Zona State 31

DAFTAR SINGKATAN

BAB I
PENDAHULUAN

1.1. Latar Belakang

Peningkatan populasi global dan penyusutan lahan subur menuntut transformasi metode pertanian konvensional menuju sistem yang lebih efisien dan berkelanjutan. Hidroponik, sebagai metode budidaya tanpa tanah, muncul sebagai solusi utama dalam pertanian modern karena kemampuannya menghemat penggunaan air secara signifikan dan meminimalkan risiko penyakit tular tanah. Namun, tidak seperti pertanian konvensional yang mengandalkan penyangga alami dari tanah, keberhasilan sistem hidroponik sangat bergantung pada presisi pengendalian parameter lingkungan, khususnya kualitas larutan nutrisi (Shareef et al., 2024). Stabilitas parameter fisikokimia dalam larutan nutrisi menjadi faktor determinan yang menentukan kualitas dan kuantitas hasil panen.

Dua parameter paling kritis dalam larutan hidroponik adalah derajat keasaman (pH) dan konduktivitas listrik (*Electrical Conductivity* atau EC). Penelitian terbaru oleh Sulaiman et al. (2025) menegaskan bahwa pertumbuhan tanaman dalam sistem hidroponik bergantung secara setara pada pengendalian pH dan EC yang ketat (Sulaiman et al., 2025). Nilai pH yang tidak optimal dapat menghambat penyerapan unsur hara esensial, di mana pH yang terlalu ekstrem (misalnya pH 4) terbukti menyebabkan stres fisiologis dan menghambat pembentukan biomassa tanaman (Marković et al., 2025). Sementara itu, EC merepresentasikan konsentrasi nutrisi terlarut yang harus dijaga dalam rentang spesifik (umumnya 0.8–3.5 mS/cm) untuk mencegah defisiensi nutrisi atau toksisitas akibat salinitas tinggi (Jain & Kaur, 2024).

Meskipun parameter ini krusial, pemantauan dan pengendalian nutrisi di banyak sistem hidroponik skala kecil hingga menengah masih dilakukan secara manual atau menggunakan kontrol umpan balik sederhana. Pendekatan manual ini tidak efisien, memakan waktu, dan rentan terhadap kesalahan manusia (*human error*) yang menyebabkan fluktuasi nutrisi yang merugikan tanaman (Jain & Kaur, 2024). Metode konvensional seperti PID (*Proportional-Integral-Derivative*)

dirancang optimal untuk sistem linear. Namun, penerapannya pada pengendalian pH sering kali menghadapi keterbatasan karena karakteristik pH yang bersifat logaritmik (sangat non-linear) dan adanya interaksi antar-parameter.

Kelemahan utama dari kontroler PID konvensional pada sistem hidroponik adalah ketidakmampuannya beradaptasi dengan perubahan kondisi tanpa penyesuaian parameter (*tuning*) yang rumit. Studi simulasi terbaru oleh Cai et al. (2025) membuktikan bahwa kontroler PID tradisional cenderung menghasilkan lonjakan respons (*overshoot*) yang tinggi, mencapai 24,5%, serta memiliki waktu penyelesaian (*settling time*) yang lambat saat menangani gangguan pada sistem fluida (Cai et al., 2025). Selain itu, karena dinamika pH bersifat sangat non-linear (logaritmik), pendekatan linear seperti PID sering kali kurang efektif dalam menjaga stabilitas di sekitar titik setel yang diinginkan tanpa menyebabkan osilasi berlebih (Panjapornpon et al., 2022). Metode lain seperti *Fuzzy Logic Controller* (FLC) memang menawarkan solusi untuk ketidakpastian, namun metode ini memiliki keterbatasan karena bergantung sepenuhnya pada aturan statis (*rule-base*) yang dirancang oleh pakar dan tidak memiliki kemampuan untuk belajar atau beradaptasi secara mandiri terhadap perubahan karakteristik sistem seiring waktu (Wang et al., 2022).

Untuk mengatasi keterbatasan metode konvensional tersebut, pendekatan berbasis kecerdasan buatan, khususnya *Reinforcement Learning* (RL), menawarkan solusi yang menjanjikan. Berbeda dengan kontroler berbasis model yang memerlukan pemodelan matematis presisi dari lingkungan, RL khususnya algoritma Q-Learning bersifat *model-free* dan mampu belajar membuat keputusan optimal melalui interaksi *trial-and-error* dengan lingkungan (Panjapornpon et al., 2022). Pendekatan ini memungkinkan sistem untuk beradaptasi secara mandiri terhadap dinamika non-linear larutan nutrisi.

Urgensi penerapan RL dalam sistem hidroponik didukung oleh bukti empiris terbaru yang signifikan. Penelitian oleh Dakshinamurthy & Mohan (2025) menunjukkan bahwa sistem kontrol berbasis RL mampu mengungguli kinerja PID konvensional secara nyata. Dalam studi komparatif mereka, sistem berbasis RL terbukti meningkatkan hasil panen tanaman hingga 12,5% sekaligus mengurangi

konsumsi sumber daya energi dan air sebesar 10–12% dibandingkan dengan kontroler PID (Dakshinamurthy & Mohan, 2024). Selain itu, penggunaan algoritma Q-Learning dinilai lebih efisien secara komputasi untuk implementasi pada perangkat keras mikrokontroler dibandingkan metode *Deep Reinforcement Learning* yang kompleks, namun tetap efektif dalam menghindari kesalahan kontrol dan mempercepat konvergensi sistem menuju kondisi optimal (Su, 2025).

Berdasarkan permasalahan stabilitas kontrol pada metode konvensional dan potensi efisiensi yang ditawarkan oleh metode pembelajaran mesin, penelitian ini bertujuan untuk mengimplementasikan algoritma *Reinforcement Learning* (Q-Learning) guna mengontrol stabilitas pH dan EC pada sistem hidroponik. Sistem ini dirancang untuk melakukan penyesuaian dosis nutrisi dan pH secara otomatis dan adaptif, guna menciptakan lingkungan pertumbuhan tanaman yang presisi, efisien sumber daya, dan minim intervensi manusia.

1.2. Rumusan Masalah

Berikut ini rumusan masalah pada penelitian ini, berdasarkan latar belakang yang telah diuraikan.

1. Bagaimana merancang arsitektur kendali modular yang mengintegrasikan mikrokontroler (ESP32) sebagai unit I/O fisik dan Raspberry Pi sebagai unit pemroses logika pusat untuk merealisasikan loop kendali tertutup (*closed-loop*) secara otonom??
2. Bagaimana merancang konfigurasi ruang keadaan (*State-Space*) dan fungsi hadiah (*Reward Function*) pada algoritma Q-Learning untuk menghasilkan kebijakan kendali yang adaptif terhadap dinamika non-linear larutan nutrisi?
3. Bagaimana karakteristik respon transien (*settling time* dan *overshoot*) serta tingkat konvergensi agen Q-Learning dalam mempertahankan stabilitas pH dan EC saat sistem menghadapi gangguan operasional?

1.3. Tujuan

Berikut ini tujuan dari penelitian ini, berdasarkan rumusan masalah yang telah diuraikan:

1. Merancang bangun arsitektur kendali modular yang mengintegrasikan mikrokontroler (ESP32) sebagai unit I/O fisik dan Raspberry Pi sebagai unit pemroses logika pusat untuk merealisasikan loop kendali tertutup (*closed-loop*) secara otonom.
2. Merancang konfigurasi ruang keadaan (*State-Space*) dan fungsi hadiah (*Reward Function*) pada algoritma Q-Learning untuk menghasilkan kebijakan kendali yang adaptif terhadap dinamika non-linear larutan nutrisi.
3. Mengevaluasi karakteristik respon transien (*settling time* dan *overshoot*) serta tingkat konvergensi agen Q-Learning dalam mempertahankan stabilitas pH dan EC saat sistem menghadapi gangguan operasional.

1.4. Manfaat Penelitian

Berikut ini manfaat dari penelitian ini:

1. Penelitian ini memberikan kontribusi terhadap pengembangan sistem kontrol otomatis pH dan EC berbasis *Machine Learning* yang mampu menyesuaikan aksi kontrolnya secara adaptif terhadap perubahan nilai sensor secara *real-time*.
2. Penelitian ini memberikan pemahaman mendalam mengenai penerapan prinsip algoritma *Reinforcement Learning* (khususnya *Q-Learning*) dalam menentukan aksi kontrol yang optimal untuk menjaga kestabilan parameter pH dan EC pada sistem hidroponik.
3. Penelitian ini menyediakan hasil analisis performa sistem kontrol berbasis *Q-Learning* dalam mempertahankan kestabilan pH dan EC terhadap variasi kondisi lingkungan melalui pengujian prototipe yang dikembangkan.

1.5. Batasan Masalah

Berikut adalah sejumlah batas yang telah ditetapkan untuk mempersempit cakupan masalah yang akan diteliti:

1. Penelitian ini hanya berfokus pada perancangan dan implementasi sistem kontrol otomatis pH dan EC pada tandon utama sistem hidroponik, tanpa membahas pengendalian pada jalur sirkulasi nutrisi atau media tanam.
2. Sistem hanya mengendalikan dua parameter utama, yaitu pH dan Electrical Conductivity (EC). Selain itu, sistem mengintegrasikan pemantauan ketinggian air (Water Level) yang berfungsi sebagai mekanisme keamanan (*safety)* untuk perlindungan aktuator dan logika pengisian air baku. Parameter lingkungan lain seperti suhu air dan kadar oksigen terlarut dianggap konstan atau tidak dikendalikan secara aktif.
3. Algoritma pembelajaran mesin yang diterapkan terbatas pada Tabular Q-Learning. Fokus penelitian ditekankan pada analisis kelayakan (feasibility) implementasi, konvergensi pembelajaran, dan kemampuan adaptasi sistem pada perangkat tertanam (embedded system). Penelitian ini tidak mencakup perbandingan kinerja (benchmarking) dengan metode kontrol konvensional (seperti PID, Fuzzy Logic) maupun varian Deep Reinforcement Learning.

1.6. Sistematika Penulisan

Penelitian pada tugas akhir ini terbagi ke dalam beberapa bagian, yang dijelaskan secara terstruktur sebagai berikut:

Bab 1 Pendahuluan

Bab ini menguraikan latar belakang masalah, rumusan masalah, tujuan penelitian, manfaat penelitian, batasan masalah, serta sistematika penulisan laporan tugas akhir.

Bab 2 Landasan Teori

Bab ini memaparkan teori-teori penunjang yang relevan dengan topik penelitian, meliputi konsep dasar hidroponik, karakteristik sensor pH dan EC, arsitektur *Internet of Things* (IoT) dan protokol MQTT, serta teori *Reinforcement Learning* khususnya algoritma Q-Learning. Bab ini juga membahas penelitian-penelitian terdahulu yang menjadi rujukan (state of the art).

Bab 3 Metodologi Penelitian

Bab ini menjelaskan tahapan pelaksanaan penelitian, mulai dari analisis kebutuhan, perancangan perangkat keras (*dosing pump panel*, integrasi sensor dengan ESP32), perancangan sistem komunikasi data, hingga perancangan agen cerdas (desain *State, Action,* dan *Reward Function*). Bab ini juga menjabarkan skenario pengujian yang akan dilakukan.

Bab 4 Hasil dan Pembahasan

Bab ini menyajikan hasil implementasi sistem dan data pengujian yang diperoleh. Pembahasan difokuskan pada analisis kinerja agen Q-Learning dalam mencapai konvergensi, serta evaluasi respon sistem kendali (seperti *settling time* dan *overshoot*) dalam menjaga stabilitas pH dan EC terhadap gangguan.

Bab 5 Penutup

Bab ini berisi kesimpulan yang diperoleh dari seluruh rangkaian penelitian serta saran-saran konstruktif untuk pengembangan sistem atau penelitian selanjutnya di masa depan.

BAB II
LANDASAN TEORI

2.1 Sistem Hidroponik dan Dinamika Nutrisi

2.1.1 Definisi dan Prinsip Kerja

Hidroponik, yang berasal dari kata Yunani *hydro* (air) dan *ponos* (kerja), adalah metode budidaya tanaman tanpa menggunakan tanah (soilless), di mana tanaman memperoleh nutrisi mineral esensial dari larutan air (Shareef et al., 2024). Metode ini merupakan bagian dari pertanian lingkungan terkontrol (*Controlled Environment Agriculture* - CEA) yang menawarkan solusi terhadap tantangan global seperti kelangkaan lahan subur dan perubahan iklim (Dakshinamurthy & Mohan, 2024).

Dibandingkan dengan pertanian konvensional, hidroponik memiliki keunggulan signifikan dalam efisiensi sumber daya. Penelitian menunjukkan bahwa sistem ini dapat mengurangi penggunaan air hingga 90% melalui mekanisme resirkulasi, menghilangkan risiko penyakit tular tanah, serta memungkinkan panen sepanjang tahun dengan hasil yang lebih tinggi per satuan luas (Dakshinamurthy & Mohan, 2024; Shareef et al., 2024). Terdapat berbagai jenis sistem hidroponik, seperti *Nutrient Film Technique* (NFT), *Deep Water Culture* (DWC), dan *Drip System* (Shareef et al., 2024). Namun, keberhasilan sistem ini sangat bergantung pada manajemen presisi parameter lingkungan, khususnya kualitas larutan nutrisi (Sulaiman et al., 2025).

2.1.2 pH (Derajat Keasaman)

Derajat keasaman (pH) adalah parameter krusial yang menentukan kelarutan dan ketersediaan unsur hara bagi akar tanaman.

- Dinamika pH: Skala pH mengukur konsentrasi ion hidrogen (H^+) dalam larutan. Sifat pH adalah logaritmik dan sangat non-linear, yang membuat proses pengendaliannya menjadi

tantangan tersendiri bagi sistem kontrol konvensional (Panjapornpon et al., 2022).

- Dampak pada Tanaman: Jika pH menyimpang dari rentang optimal (umumnya 5.5–6.5), tanaman akan mengalami *nutrient lockout*, di mana unsur hara tertentu mengendap dan tidak dapat diserap (Shareef et al., 2024). Marković et al. (2025) menemukan bahwa pH yang tidak optimal (misalnya terlalu asam di pH 4) menyebabkan stres fisiologis yang menghambat akumulasi biomassa dan tinggi tanaman (Marković et al., 2025). Sebaliknya, pada kondisi basa (pH tinggi), ketersediaan mikronutrien seperti Besi (Fe) dan Mangan (Mn) menurun drastis, menyebabkan klorosis (Marković et al., 2025). Oleh karena itu, menjaga stabilitas pH sangat penting untuk memaksimalkan hasil panen (Sulaiman et al., 2025).

2.1.3 Electrical Conductivity (EC)

Electrical Conductivity (EC) adalah indikator jumlah total garam mineral terlarut (TDS) dalam larutan nutrisi.

- Hubungan dengan Nutrisi: EC berbanding lurus dengan konsentrasi nutrisi, semakin banyak nutrisi yang dilarutkan, semakin tinggi nilai EC (Jain & Kaur, 2024).
- Dampak Fisiologis: Pengendalian EC harus presisi. Jika EC terlalu rendah, tanaman akan mengalami defisiensi nutrisi yang menghambat pertumbuhan. Sebaliknya, jika EC terlalu tinggi (salinitas berlebih), tanaman akan mengalami stres osmotik yang menghambat penyerapan air oleh akar dan dapat menyebabkan toksisitas ion (Marković et al., 2025). Shareef et al. (2024) merekomendasikan rentang EC optimal antara 0.8 hingga 3.5 mS/cm tergantung pada jenis tanaman untuk mencegah stres garam (Shareef et al., 2024).

2.1.4 Interaksi pH dan EC sebagai Sistem Multivariabel

Dalam implementasi kontrol otomatis, pH dan EC tidak dapat dianggap sebagai variabel yang terpisah sepenuhnya karena adanya interaksi kimia. Penambahan larutan korektor pH (asam/basa) seringkali mempengaruhi total ion terlarut, yang secara tidak sengaja dapat mengubah nilai EC (Sulaiman et al., 2025). Selain itu, volume air dalam tangki (*Nutrient Solution Volume*) juga mempengaruhi konsentrasi ion, penguapan air akan meningkatkan EC dan mengubah pH, menciptakan dinamika sistem yang kompleks dan *time-varying* (Sulaiman et al., 2025). Kompleksitas dan non-linearitas inilah yang menjadi landasan utama mengapa metode kontrol cerdas seperti *Reinforcement Learning* diperlukan untuk menggantikan kontroler linear klasik (seperti PID) yang sering mengalami kesulitan dalam menangani gangguan tersebut (Dakshinamurthy & Mohan, 2024; Panjapornpon et al., 2022).

2.2 Penelitian Terkait

Perkembangan sistem kendali pada pertanian presisi, khususnya hidroponik, telah berevolusi dari metode konvensional menuju sistem cerdas yang adaptif. Tinjauan sistematis yang dilakukan oleh Catota-Ocapana et al. (2025) terhadap 654 artikel menunjukkan bahwa tren penelitian saat ini berfokus pada integrasi *Artificial Intelligence* (AI) dan *Internet of Things* (IoT) untuk manajemen nutrisi, menggantikan metode umpan balik klasik yang memiliki keterbatasan dalam menangani dinamika tanaman yang kompleks (Catota-Ocapana et al., 2025; Hutauruk, 2025). Berikut adalah analisis mendalam mengenai metode-metode kendali yang telah diterapkan sebelumnya beserta keterbatasannya.

2.2.1 Finite State Machine

Metode *Finite State Machine* (FSM) merupakan pendekatan logika berbasis aturan sekuensial yang banyak digunakan karena kesederhanaannya dalam implementasi mikrokontroler.

- Implementasi: Hutauruk (2025) mengembangkan sistem kendali otomatis untuk ketinggian air dan nutrisi pada hidroponik rakit apung menggunakan metode FSM. Sistem ini bekerja berdasarkan transisi keadaan (*state*) yang telah didefinisikan secara kaku, seperti "Siaga Air", "Siaga Nutrisi", "Siaga Darurat", dan "Normal" berdasarkan input dari sensor ultrasonik dan TDS (Hutauruk, 2025)
- Kelemahan: Meskipun sistem ini berhasil mengaktifkan pompa secara otomatis berdasarkan ambang batas (*threshold*), FSM memiliki keterbatasan utama yaitu sifatnya yang deterministik dan kaku. Sistem hanya merespons berdasarkan logika *if-then* yang telah diprogram sebelumnya dan tidak memiliki kemampuan untuk beradaptasi atau "belajar" jika terjadi perubahan dinamika lingkungan yang tidak terduga di luar aturan transisi yang ditetapkan (Hutauruk, 2025).

2.2.2 PID (Propotional-Integral-Derivative)

Kontroler PID merupakan standar industri yang banyak digunakan untuk menjaga kestabilan parameter lingkungan. Namun, efektivitasnya sering kali menurun pada sistem non-linear seperti pengendalian pH air.

- Implementasi: Cai et al. (2025) melakukan simulasi perbandingan kinerja kontroler pada suhu larutan nutrisi.
- Kelemahan: Hasil penelitian menunjukkan bahwa kontroler PID konvensional memiliki kelemahan signifikan dalam menangani gangguan. PID menghasilkan waktu penyelesaian (settling time) yang lama (hingga 200,36 detik) dan lonjakan (overshoot) yang tinggi mencapai 24,5% sebelum mencapai kestabilan (Cai et al., 2025).
- Analisis: Wang et al. (2022) dan Panjapornpon et al. (2022) menambahkan bahwa proses regulasi EC dan pH memiliki karakteristik non-linearitas, penundaan waktu (time delay), dan variasi waktu (time-varying). Kontroler PID tradisional, yang

dirancang untuk sistem linear sederhana, sering kali menghasilkan kesalahan besar dan osilasi berkelanjutan dalam regulasi EC dan pH, sehingga memerlukan penyetelan (tuning) parameter yang rumit dan berulang,(Panjapornpon et al., 2022; Wang et al., 2022).

2.2.3 Fuzzy Logic Controller (FLC)

Untuk mengatasi ketidaklinieran PID, banyak peneliti beralih ke *Fuzzy Logic Controller* (FLC) yang meniru logika pengambilan keputusan manusia.

- Implementasi: Ridwan et al. (2024) mengimplementasikan FLC untuk menjaga kestabilan pH dan EC. Sistem ini menggunakan aturan linguistik (seperti "Jika pH Asam, maka Pompa pH Up Lama") dan berhasil mencapai akurasi pH sebesar 99% dan EC sebesar 98,7% (Agustian et al., 2022; Ridwan et al., 2025). Serupa dengan itu, Agustian et al. (2022) menggunakan metode *Mamdani Fuzzy Inference System* untuk mengontrol durasi aktif pompa nutrisi berdasarkan masukan sensor (Agustian et al., 2022).
- Kelemahan: Kendati efektif, Catota-Ocapana et al. (2025) menyoroti bahwa FLC sangat bergantung pada basis pengetahuan (*knowledge base*) yang dirancang oleh pakar. Kelemahannya adalah kurangnya kemampuan belajar mandiri, jika karakteristik sistem berubah (misalnya degradasi pompa atau perubahan volume tangki), FLC tidak dapat menyesuaikan aturan kendalinya secara otomatis tanpa desain ulang oleh manusia(Catota-Ocapana et al., 2025).

2.2.4 Research Gap

Berdasarkan analisis terhadap metode FSM, PID, dan FLC di atas, ditemukan kesenjangan penelitian (*research gap*) sebagai berikut:

1. Kekakuan Adaptasi metode FSM dan PID bersifat kaku dan sulit menangani non-linearitas tinggi pada dinamika pH dan EC tanpa model matematis yang presisi.
2. Ketergantungan pada Model/Pakar metode FLC sangat bergantung pada aturan pakar yang statis dan tidak mampu belajar dari pengalaman baru secara *real-time*.
3. Efisiensi Sumber Daya metode konvensional sering kali menyebabkan *overshoot* (pemborosan larutan nutrisi/air) seperti yang ditunjukkan pada kinerja PID dengan *overshoot* 24,5% (Cai et al., 2025).

Dibutuhkan sebuah metode kendali yang bersifat model-free (tidak butuh model matematis rumit), adaptif (bisa belajar sendiri), dan mampu mengoptimalkan penggunaan sumber daya secara mandiri.

2.2.5 Solusi Reinforcement Learning (Q-Learning).

Untuk mengisi kesenjangan penelitian tersebut, penelitian ini mengusulkan penggunaan algoritma *Q-Learning*. Berbeda dengan metode kontrol konvensional maupun metode *Deep Reinforcement Learning* (DRL) yang kompleks, Q-Learning dipilih karena menawarkan keseimbangan antara kemampuan adaptasi dan efisiensi komputasi.

1. Kemampuan *Model-Free* dan *Off-Policy s*eperti halnya pendekatan RL lainnya, Q-Learning tidak memerlukan model matematis proses yang presisi (seperti yang dibutuhkan PID atau MPC). Morcego et al. (2023) menjelaskan bahwa pendekatan *model-free* memungkinkan agen belajar langsung dari interaksi lingkungan, menjadikannya fleksibel terhadap dinamika pH yang sangat non-linear (Morcego et al., 2023). Q-Learning secara spesifik adalah algoritma *off-policy*, yang artinya dapat memisahkan kebijakan eksplorasi (mencoba hal baru) dan eksploitasi (menggunakan pengetahuan terbaik),

memungkinkan pencarian solusi optimal global tanpa terjebak pada aturan kaku (Morcego et al., 2023).

2. Efisiensi Komputasi Dibandingkan *Deep RL* banyak penelitian terbaru, seperti Dakshinamurthy & Mohan (2024) dan Panjapornpon et al. (2022), menerapkan algoritma tingkat lanjut seperti *Deep Deterministic Policy Gradient* (DDPG) atau PPO untuk kontrol proses (Dakshinamurthy & Mohan, 2024; Panjapornpon et al., 2022). Meskipun metode tersebut sangat presisi untuk ruang aksi kontinu, mereka membutuhkan sumber daya komputasi yang besar (GPU/High-end CPU) dan waktu pelatihan yang lama karena melibatkan *Deep Neural Networks*. Sebaliknya, Q-Learning berbasis tabel (Tabular Q-Learning) yang digunakan dalam penelitian ini jauh lebih ringan secara komputasi. Pendekatan ini memungkinkan implementasi langsung pada perangkat *edge* dengan sumber daya terbatas (seperti Raspberry Pi) tanpa mengorbankan kemampuan adaptifnya secara signifikan. Hal ini sejalan dengan temuan bahwa algoritma RL yang lebih sederhana sering kali lebih praktis untuk aplikasi *real-time* dengan *state-space* yang dapat didiskritisasi (Morcego et al., 2023; Panjapornpon et al., 2022).
3. Mekanisme *Reward* untuk Stabilitas kunci keberhasilan Q-Learning terletak pada perancangan fungsi *reward*. Penelitian ini mengadopsi strategi di mana agen diberi *reward* positif saat menjaga pH/EC pada *setpoint* dan penalti besar saat terjadi *overshoot*, sebuah pendekatan yang terbukti mampu mengurangi osilasi yang sering terjadi pada kontroler PID konvensional pada sistem non-linear (Panjapornpon et al., 2022).

2.3 Reinforcement Learning dan Algoritma Q-Learning

2.3.1 Konsep Dasar Reinforcement Learning (RL)

Reinforcement Learning (RL) merupakan paradigma pembelajaran mesin di mana sebuah agen (*agent*) belajar membuat keputusan secara

berurutan melalui interaksi *trial-and-error* dengan lingkungannya. Berbeda dengan *supervised learning* yang bergantung pada data terlabel, ataupun *unsupervised learning* yang bekerja tanpa luaran yang ditentukan sebelumnya untuk menyingkap pola tersembunyi (*hidden patterns*) dalam data tak berlabel (Abdulkadir et al., 2025; Munaf & Almusawi, 2024), RL memiliki orientasi tujuan yang berbeda. Jika dibandingkan dengan kontroler konvensional seperti PID yang memerlukan penalaan parameter manual, RL secara spesifik berfokus pada maksimalisasi sinyal hadiah numerik kumulatif (*cumulative reward*) yang diterima dari lingkungan sebagai umpan balik atas tindakan yang diambil (Panjapornpon et al., 2022).

Dalam konteks sistem kendali, RL menawarkan pendekatan *model-free*, yang berarti agen tidak memerlukan model matematis yang presisi dari dinamika fisik atau kimia sistem (seperti kinetika reaksi asam-basa) untuk dapat mengendalikannya. Hal ini menjadikan RL sangat adaptif terhadap gangguan lingkungan yang dinamis dan ketidakpastian sistem, dibandingkan dengan metode kontrol berbasis model seperti *Model Predictive Control* (MPC) yang kinerjanya sangat bergantung pada akurasi model matematis yang dibuat (Morcego et al., 2023).

Interaksi antara agen dan lingkungan dalam RL dimodelkan sebagai *Markov Decision Process* (MDP), seperti yang diilustrasikan pada Gambar 2.1. MDP terdiri dari empat elemen utama (Lu et al., 2023):

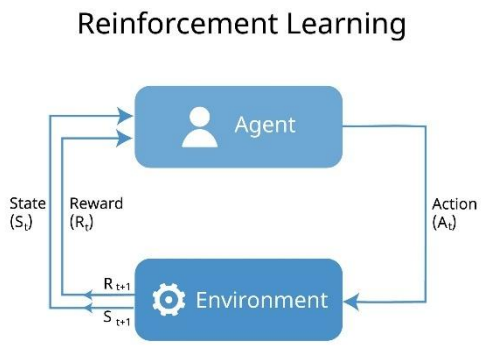

Gambar 2. 1 Ilustrasi Interaksi Agen dan Lingkungan dalam Reinforcement Learning

1. State (S_t): Representasi kondisi lingkungan saat ini. Dalam penelitian ini, *state* adalah nilai pembacaan sensor pH dan EC.
2. Action (A_t): Tindakan yang diambil oleh agen untuk mempengaruhi lingkungan. Dalam konteks ini, *action* adalah durasi pengaktifan pompa peristaltik (dosing).
3. Reward (R_t): Sinyal umpan balik skalar yang memberitahu seberapa baik atau buruk tindakan yang diambil pada *state* tertentu.
4. Policy (π): Strategi atau kebijakan yang digunakan agen untuk memetakan *state* ke *action* guna mencapai tujuan kontrol.

2.3.2 Algoritma Q-Learning.

Q-Learning adalah salah satu algoritma *Reinforcement Learning* (RL) yang paling populer dan banyak digunakan dalam sistem kendali otonom karena sifatnya yang *model-free* (tidak memerlukan model matematis dari lingkungan) dan *off-policy*. Algoritma ini memungkinkan agen untuk mempelajari strategi kontrol yang optimal dengan mengevaluasi utilitas atau "kualitas" (dilambangkan sebagai Q) dari setiap tindakan yang diambil pada suatu keadaan tertentu tanpa perlu mengetahui dinamika fisika atau kimia yang kompleks dari sistem tersebut (Munaf & Almusawi, 2024).

Prinsip dasar Q-Learning adalah mempelajari fungsi nilai aksi (action-value function), $Q(s, a)$, yang merepresentasikan nilai imbalan jangka panjang yang diharapkan (expected cumulative reward) jika agen mengambil aksi a pada keadaan s dan kemudian mengikuti kebijakan optimal setelahnya. Berbeda dengan metode kontrol konvensional seperti PID yang bergantung pada parameter tetap, Q-Learning memperbarui pengetahuannya secara iteratif melalui interaksi *trial-and-error* dengan lingkungan (Munaf & Almusawi, 2024).

Proses pembelajaran Q-Learning melibatkan pembaruan tabel nilai Q (*Q-Table*) menggunakan Persamaan Bellman. Persamaan ini menghitung selisih temporal (*Temporal Difference error*) antara nilai Q

saat ini dengan nilai target yang didasarkan pada *reward* yang diterima dan estimasi nilai masa depan terbaik. Rumus pembaruan Q-Learning dinyatakan sebagai berikut (Munaf & Almusawi, 2024):

$$Q(s,a) \leftarrow Q(s,a) + \alpha\left[r + \gamma \cdot \max_{a'} Q\,(s',a') - Q(s,a)\right]$$

Dimana:

$Q(s,a)$	: Nilai Q saat ini untuk keadaan s dan aksi α
α (*Learning Rate)*	: Laju pembelajaran $(0 < \alpha \leq 1)$ yang menetukan seberapa cepat agen mengadopsi informasi baru dibandingkan informasi lama. Nilai yang terlalu rendah menyebabkan pembelajaran lambat, sedangkan nilai terlalu tinggi membuat sistem tidak stabil.
r *(Reward)*	: Imbalan langsung yang diterima dari lingkungan setelah melakukan aksi.
γ (*Discount Factor)*	: Faktor diskon $(0 \leq \gamma < 1)$ menentukan pentingnya imbalan masa depan dibandingkan imbalan saat ini. Nilai mendekati 1 membuat agen lebih mementingkan tujuan jangka panjang (stabilitas jangka panjang)
$\max_{a'} Q\,(s',a')$	: Estimasi nilai Q maksimum yang mungkin didapatkan pada keadaan berikutnya (s').

2.4 Arsitektur Sitem Kendali Terdistribusi

Sistem kendali modern pada pertanian presisi, khususnya hidroponik, sering kali mengadopsi arsitektur terdistribusi yang memisahkan fungsi akuisisi data (*sensing*) dan fungsi pengambilan keputusan (*decision making*). Pendekatan ini bertujuan untuk meningkatkan keandalan sistem, meminimalkan latensi, dan memungkinkan pengelolaan data yang kompleks secara *real-time* (Tatas et al., 2022; Wang et al., 2022).

2.4.1 Lapisan Persepsi dan Pengambilan Keputusan

Dalam arsitektur *Internet of Things* (IoT) untuk hidroponik, sistem dibagi menjadi beberapa node fungsional:

1. Node Sensor (*Sensing Node/Slave Node*): Bertugas mengumpulkan data parameter lingkungan seperti pH, *Electrical Conductivity* (EC), suhu air, dan kelembaban. Node ini mengubah sinyal analog dari sensor menjadi data digital dan mengirimkannya ke unit pemroses utama. Tatas et al. menjelaskan bahwa node ini juga dapat bertindak sebagai eksekutor yang mengaktifkan aktuator (seperti pompa atau *solenoid valve*) berdasarkan perintah dari pusat kendali (Tatas et al., 2022).
2. Node Kendali Pusat (*Master/Decision Node*): Merupakan unit komputasi yang lebih tinggi yang menerima data dari node sensor, memproses algoritma kendali (seperti logika *fuzzy* atau *neural network*), dan mengirimkan kembali sinyal aksi. Pemisahan ini memungkinkan penerapan algoritma cerdas yang membutuhkan daya komputasi besar tanpa membebani node sensor yang biasanya memiliki sumber daya terbatas (Tatas et al., 2022; Wang et al., 2022).

2.4.2 Protokol Komunikasi Data

Komunikasi antar-node dalam sistem terdistribusi memerlukan protokol yang efisien untuk menjamin integritas data. Protokol komunikasi yang menggunakan mekanisme *publish-subscribe* sering digunakan dalam arsitektur ini. Dalam mekanisme ini, node sensor bertindak sebagai *publisher* yang mengirimkan data ke topik tertentu, sementara node kendali bertindak sebagai *subscriber* yang menerima data tersebut untuk diproses (Wang et al., 2022). Penggunaan protokol telemetri seperti MQTT (*Message Queuing Telemetry Transport*) sangat relevan dalam sistem hidroponik cerdas karena kemampuannya menangani transmisi data pada *bandwidth* rendah dengan latensi minimal, yang krusial untuk menjaga kestabilan pengendalian nutrisi secara *real-time*(Sulaiman et al., 2025).

2.4.3 Mekanisme Keamanan (Safety Interlock)

Sistem otomatisasi yang melibatkan cairan dan aktuator listrik memerlukan mekanisme keamanan untuk mencegah kegagalan perangkat keras. Salah satu risiko utama dalam sistem hidroponik adalah *dry running* (pompa beroperasi tanpa air) atau *overflow* (air meluap). Untuk memitigasi risiko ini, diterapkan logika *Finite State Machine* (FSM) yang mengintegrasikan sensor ketinggian air (*water level*). Hutauruk menjelaskan bahwa FSM memungkinkan sistem berpindah ke keadaan "Siaga Darurat" atau mematikan pompa secara otomatis apabila sensor mendeteksi ketinggian air berada di bawah batas aman, terlepas dari perintah algoritma kendali utama (Hutauruk, 2025). Mekanisme *safety interlock* ini memastikan bahwa optimasi nutrisi tidak mengorbankan keamanan fisik perangkat keras (Kurniawan & Amirullah, 2021).

2.5 Parameter Evaluasi Performasi Kontrol

Untuk mengukur efektivitas dan stabilitas algoritma kendali cerdas (seperti *Reinforcement Learning*) dalam menjaga setpoint pH dan EC, diperlukan metrik evaluasi kuantitatif yang baku. Evaluasi ini umumnya dibagi menjadi analisis respon transien dan analisis galat integral.

2.5.1 Karakteristik Respon Transien

Analisis respon transien digunakan untuk melihat perilaku sistem sesaat setelah diberikan gangguan atau perubahan target. Parameter kunci dalam evaluasi ini meliputi:

1. *Settling Time* (Waktu Tunak): Didefinisikan sebagai waktu terpendek yang dibutuhkan oleh variabel respon untuk masuk dan tetap berada dalam batas toleransi kesalahan tertentu (biasanya ±2% atau ±5%) dari nilai akhir yang diinginkan (Cai et al., 2025). Semakin singkat *settling time*, semakin responsif sistem dalam memulihkan kondisi nutrisi ideal bagi tanaman (Ridwan et al., 2025).
2. *Overshoot* (Lonjakan Maksimum): Merupakan rasio deviasi maksimum dari variabel respon yang melampaui nilai *steady-*

state. Dalam konteks hidroponik, *overshoot* yang berlebihan pada penambahan larutan asam atau basa dapat menyebabkan kejutan (*shock*) pada akar tanaman. Sistem kendali yang baik harus mampu meminimalkan persentase *overshoot* ini (Cai et al., 2025; Su, 2025).

2.5.2 Konvergensi Agen Pembelajaran

Khusus untuk sistem berbasis *Reinforcement Learning* (RL), kinerja juga dievaluasi berdasarkan konvergensi *reward*. Konvergensi tercapai ketika agen mampu memaksimalkan akumulasi *reward* (imbalan) dan menstabilkan nilai fungsi Q (*Q-value*) seiring bertambahnya episode pembelajaran. Grafik pembelajaran (*learning curve*) yang menunjukkan peningkatan *reward* kumulatif dan penurunan variansi kesalahan mengindikasikan bahwa agen telah berhasil mempelajari kebijakan (*policy*) optimal untuk mengendalikan lingkungan(Bashabsheh, 2024; Cai et al., 2025)

BAB III
METODOLOGI PENELITIAN

3.1 Alur Penelitian

Tahapan pelaksanaan penelitian ini disusun secara sistematis untuk memastikan tujuan perancangan sistem kendali adaptif tercapai. Alur kerja penelitian, mulai dari identifikasi masalah hingga evaluasi kinerja akhir, diilustrasikan pada Gambar 3.1.

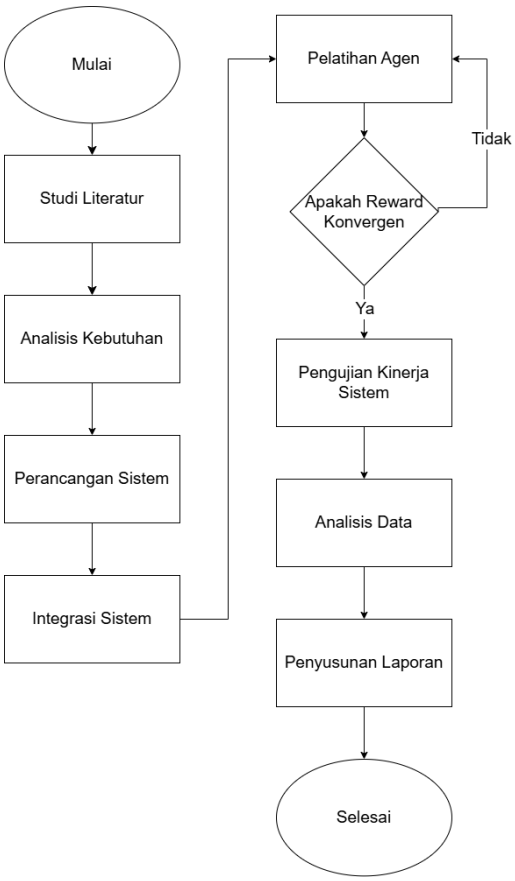

Gambar 3. 1 Diagram Alir Tahapan Penelitian

Secara garis besar, prosedur penelitian terdiri dari beberapa fase utama:

1. Tahapan Persiapan penelitian dimulai dengan studi literatur untuk mempelajari teori tentang karakteristrik pH, EC, dan algoritma *Reinforcement Learning*, yang dilanjutkan dengan Analisis Kebutuhan untuk menentukan spesifikasi komponen perangkat keras seperti (sensor, pompa, mikrokontroler) dan kebutuhan perangkat lunak.

2. Tahap Perancangan dan Integrasi berdasarkan analisis tersebut, dilakukan Perancangan Sistem yang mencakup desain mekanik, elektronik, dan arsitektur agen cerdas. Seluruh komponen kemudian disatukan pada tahap Integrasi Sistem agar siap beroperasi.
3. Tahap Pelatihan Agen (*Training Loop*) ini merupakan inti dari penerapan metode Q-Learning. Sistem akan memasuki tahap Pelatihan Agen di mana agen belajar berinteraksi dengan lingkungan. Seperti terlihat pada diagram alir, terdapat proses evaluasi apakah *reward* konvergen. Jika akumulasi *reward* belum mencapai titik konvergen (stabil), proses pelatihan akan diulang kembali. Agen dianggap "pintar" hanya jika grafik *reward* telah konvergen.
4. Tahap Pengujian dan Analisis setelah agen terlatih, dilakukan Pengujian Kinerja Sistem untuk mengukur parameter respon transien (*overshoot* dan *settling time*). Data yang diperoleh kemudian diolah pada tahap Analisis Data untuk ditarik kesimpulannya dalam Penyusunan Laporan.

3.2 Perancangan Arsitektur Sistem

Perancangan sistem kendali pada penelitian ini mengadopsi arsitektur terdistribusi (*distributed control system*) yang memisahkan fungsi akuisisi data, pengambilan keputusan, dan eksekusi kontrol ke dalam perangkat keras yang berbeda. Pendekatan ini dipilih untuk meningkatkan keandalan sistem dan meminimalisir interferensi sinyal (*noise*) antara sirkuit sensor yang sensitif dan sirkuit aktuator yang memiliki beban induktif tinggi.

Secara fungsional, hubungan antar-komponen perangkat keras dan aliran data dalam sistem ditunjukkan pada Gambar 3.2.

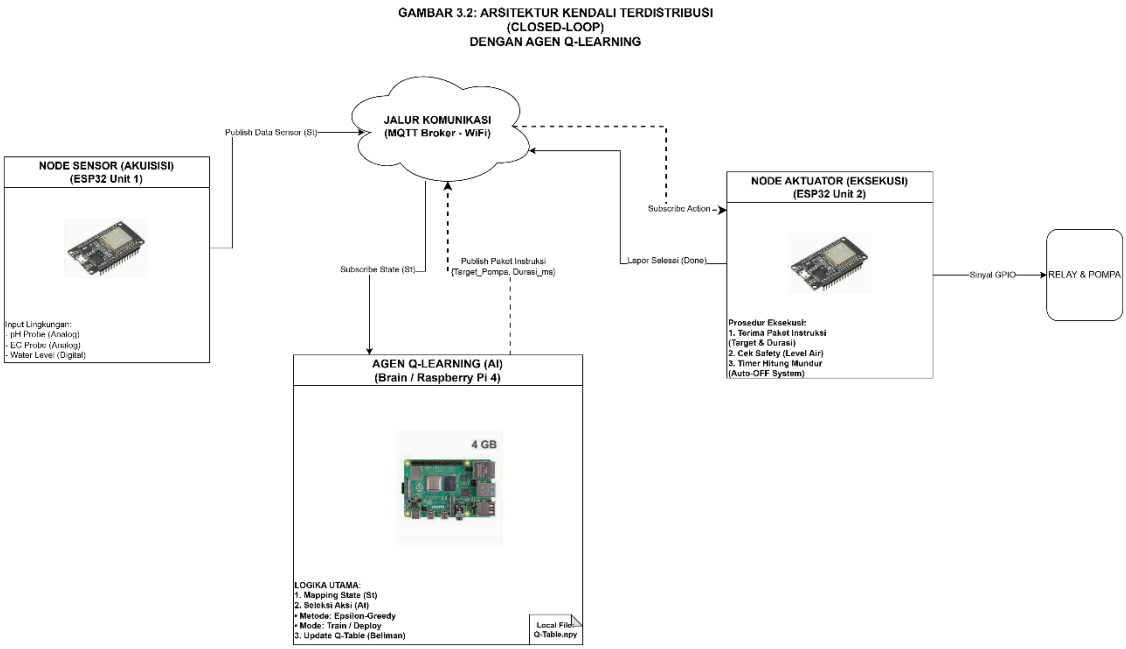

Gambar 3.2 Diagram Blok Arsitektur Sistem Kendali Terdistribusi.

Seperti yang diilustrasikan pada Gambar 3.2, sistem terdiri dari tiga *node* pemrosesan utama yang saling terhubung melalui jaringan nirkabel:

1. Node Sensor (Sensing Node) ini menggunakan mikrokontroler ESP32 Unit 1 yang berfungsi khusus sebagai *slave* untuk akuisisi data. Node ini terhubung dengan sensor pH, sensor EC, dan sensor *water level*. Data analog yang dibaca akan diproses dan dikonversi menjadi data digital, kemudian dikirimkan (*publish*) ke *broker* MQTT. Pemisahan node ini bertujuan untuk menjaga integritas data sensor dari gangguan elektromagnetik yang mungkin ditimbulkan oleh motor pompa.
2. Node Kendali Cerdas (*Decision Node*) pusat pemrosesan logika dijalankan oleh komputer papan tunggal Raspberry Pi 4. Perangkat ini bertindak sebagai 'Agen' dalam algoritma *Reinforcement Learning* (RL). Raspberry Pi bertugas menerima data *state* (S_t) dari Node Sensor, menghitung nilai *Q-Function*, dan menentukan aksi (A_t) terbaik berdasarkan kebijakan (*policy*) yang sedang dipelajari. Keputusan durasi nyala pompa kemudian dikirimkan kembali ke

jaringan MQTT, dan agen akan menunggu status penyelesaian aksi sebelum memulai siklus observasi berikutnya

3. Node Aktuator (*Actuating Node*) node ini menggunakan mikrokontroler ESP32 Unit 2 yang terpisah secara fisik dari node sensor. Tugas utamanya adalah menerima (*subscribe*) perintah aksi dari Raspberry Pi dan mengendalikan modul *relay* 6-channel. Setelah durasi pemompaan selesai, node ini mempublikasikan sinyal status (*acknowledgment*) kembali ke broker untuk menginformasikan agen bahwa aksi telah tuntas dieksekusi. *Relay* ini akan mengatur nyala-mati pompa peristaltik untuk larutan pH Up, pH Down, Nutrisi A, dan Nutrisi B sesuai durasi yang diperintahkan.
4. Jalur Komunikasi Data pertukaran informasi antar-node difasilitasi oleh protokol MQTT (*Message Queuing Telemetry Transport*). Protokol ini dipilih karena kemampuannya yang ringan dan efisien untuk komunikasi *real-time* pada sistem IoT.

Selain pengendalian nutrisi, sistem ini juga menerapkan mekanisme keamanan (*safety interlock*). Data dari sensor *water level* digunakan sebagai syarat logika jika ketinggian air terdeteksi di bawah batas aman, Node Aktuator akan memblokir perintah pompa untuk mencegah kerusakan akibat *dry running* (pompa bekerja tanpa air).

3.3 Perancangan Hardware

Realisasi fisik sistem kendali dibangun berdasarkan arsitektur terdistribusi yang telah dirancang. Perangkat keras dibagi menjadi tiga modul utama yang terpisah secara fisik untuk menjamin isolasi elektrik dan kemudahan perawatan (*maintenance*). Spesifikasi dan konfigurasi perangkat keras adalah sebagai berikut:

1. Modul Sensor (*Sensing Unit*): Unit ini difungsikan khusus untuk akuisisi data lingkungan guna menghindari interferensi sinyal (*noise*) dari beban induktif.

- Mikrokontroler: Menggunakan ESP32 DevKit V1 (Unit 1) sebagai pemroses sinyal analog-ke-digital (ADC).
- Sensor: Terdiri dari sensor pH analog (tipe SEN0161) dan sensor *Electrical Conductivity* (tipe DFR0300) yang terhubung ke pin GPIO analog ESP32. Sensor ultrasonik ditambahkan untuk pemantauan level air secara non-kontak.
- Catu Daya: Menggunakan suplai daya teregulasi 5V DC terpisah untuk menjaga stabilitas pembacaan sensor presisi.

2. Modul Aktuator (*Dosing Unit*): Unit ini bertugas mengeksekusi perintah fisik dan mengelola beban daya motor.
    - Mikrokontroler: Menggunakan ESP32 DevKit V1 (Unit 2) sekunder yang beroperasi sebagai *MQTT Subscriber*.
    - Driver: Modul Relay 6-Channel (5V, *Active Low*) yang dilengkapi *optocoupler* untuk isolasi galvanik antara mikrokontroler dan sirkuit daya pompa.
    - Pompa: 5 unit pompa peristaltik 12V DC digunakan untuk memompa larutan korektor (pH Up, pH Down), larutan nutrisi (Stok A, Stok B), dan air baku (untuk dilusi).
3. Unit Komputasi Pusat (*Edge Server*)
    - Menggunakan Raspberry Pi 4 Model B (RAM 4GB) yang berfungsi sebagai *MQTT Broker* lokal dan *host* untuk algoritma agen cerdas. Perangkat ini ditempatkan dalam panel berventilasi aktif untuk menjaga suhu operasi prosesor tetap optimal selama proses pelatihan (*training*) yang memakan sumber daya komputasi.

3.4 Perancangan Agen Cerdas

Setelah perancangan perangkat keras dan arsitektur komunikasi data selesai, tahapan selanjutnya adalah perancangan logika kecerdasan buatan. Agen cerdas dalam penelitian ini dibangun menggunakan algoritma *Reinforcement Learning* dengan pendekatan *Model-Free*, di mana agen belajar menentukan strategi kendali optimal melalui interaksi langsung dengan lingkungan tanpa memerlukan pemodelan matematis sistem yang kompleks.

Perancangan agen didasarkan pada kerangka kerja *Markov Decision Process* (MDP) yang memetakan dinamika sistem hidroponik ke dalam empat komponen fundamental, yaitu:

1. Ruang Keadaan (*State-Space*): Representasi numerik dari kondisi kualitas air (pH dan EC) yang dibaca oleh sensor.

2. Ruang Aksi (*Action-Space*): Himpunan keputusan kendali durasi pompa yang dapat dieksekusi oleh agen.

3. Tabel Pengetahuan (*Q-Table*): Struktur memori berbentuk matriks tempat agen menyimpan nilai utilitas (*Q-Value*) dari setiap pengalaman pembelajaran.

4. Fungsi Hadiah (*Reward Function*): Mekanisme evaluasi untuk memberikan umpan balik positif atau negatif terhadap kinerja agen.

Rincian perancangan teknis untuk setiap komponen tersebut dijabarkan pada sub-bab berikut.

3.4.1 Definisi Ruang Keadaan (State-Space)

Data kualitas air yang diakuisisi oleh node sensor (ESP32) berupa nilai pH dan EC memiliki format kontinu (*floating point*). Agar agen Q-Learning dapat memproses data tersebut dalam tabel keputusan yang terbatas, nilai pembacaan sensor harus didiskritisasi menjadi level-level diskrit. Langkah ini bertujuan untuk mereduksi dimensi data lingkungan (*dimensionality reduction*) sehingga beban komputasi pada perangkat pemroses pusat (Raspberry Pi) menjadi lebih efisien. Pembagian menjadi 5 level (termasuk '*Very Low*' dan '*Very High*') dipilih untuk memberikan resolusi yang cukup bagi agen dalam membedakan antara kondisi yang masih dapat ditoleransi (*Low/High*) dan kondisi yang memerlukan intervensi darurat (*Very Low/Very High*), sehingga mencegah respons kendali yang terlalu agresif pada penyimpangan kecil.

Implementasi diskritisasi membagi rentang ukur masing-masing parameter menjadi 5 kategori spesifik, yaitu *Very Low*, *Low*, *Optimal*, *High*, dan *Very High*. Penentuan ambang batas (*threshold*) untuk setiap kategori menerapkan

ketidaksamaan matematis yang ketat (*strict inequality*) untuk menjamin tidak adanya tumpang tindih (*overlap*) pada pembacaan sensor. Rincian aturan pembagian level untuk parameter pH disajikan pada Tabel 3.1.

Tabel 3.1 Aturan Diskritisasi Parameter pH

Level	Kategori	Rentang Nilai pH
0	Very Low	$pH < 5.5$
1	Low	$5.5 \leq pH < 5.8$
2	Optimal	$5.8 \leq pH \leq 6.2$
3	High	$6.2 < pH \leq 6.5$
4	Very High	$pH > 6.5$

Sementara itu, parameter EC juga dibagi menjadi 5 level kategori berdasarkan konsentrasi nutrisi terlarut, seperti terlihat pada Tabel 3.2

Tabel 3. 2 Aturan Diskritisasi Parameter EC

Level	Kategori	Rentang Nilai EC ($\mu S/cm$)
0	Very Low	$EC < 800$
1	Low	$800 \leq EC < 1100$
2	Optimal	$1100 \leq EC \leq 1300$
3	High	$1300 < EC \leq 1600$
4	Very High	$EC > 1600$

Kedua tabel diskritisasi di atas (Tabel 3.1 dan Tabel 3.2) mendefinisikan level secara parsial untuk masing-masing sensor. Namun, dalam algoritma Q-Learning, agen harus mempersepsikan lingkungan sebagai satu kesatuan kondisi global yang utuh. Oleh karena itu, ruang keadaan (*State-Space*) dibentuk melalui mekanisme pemetaan silang (*State Mapping*) yang mengombinasikan indeks pH dan EC menjadi 25 identitas keadaan unik.

Penentuan State (S_t) dilakukan menggunakan metode pemetaan langsung (*Direct Mapping*). Sistem mengidentifikasi pertemuan antara indeks Level pH dan

Level EC, lalu mencocokkannya dengan ID keadaan unik yang tertera secara spesifik pada Tabel 3.3.

Tabel 3. 3 Matriks Pemetaan Ruang Keadaan (State Mapping Matrix)

State ID	pH Index	EC Index	Kategori Zona
1	0 (VL)	0 (VL)	Kritis Ekstrem
2	0 (VL)	1 (L)	Kritis
3	0 (VL)	2 (Opt)	Kritis
4	0 (VL)	3 (H)	Kritis
5	0 (VL)	4 (VH)	Kritis Ekstrem
6	1 (L)	0 (VL)	Kritis
7	1 (L)	1 (L)	Transisi
8	1 (L)	2 (Opt)	Sub-Optimal
9	1 (L)	3 (H)	Transisi
10	1 (L)	4 (VH)	Kritis
11	2 (Opt)	0 (VL)	Kritis
12	2 (Opt)	1 (L)	Sub-Optimal
13	2 (Opt)	2 (Opt)	Target (Goal)
14	2 (Opt)	3 (H)	Sub-Optimal
15	2 (Opt)	4 (VH)	Kritis
16	3 (H)	0 (VL)	Kritis
17	3 (H)	1 (L)	Transisi
18	3 (H)	2 (Opt)	Sub-Optimal
19	3 (H)	3 (H)	Transisi
20	3 (H)	4 (VH)	Kritis
21	4 (VH)	0 (VL)	Kritis Ekstrem
22	4 (VH)	1 (L)	Kritis
23	4 (VH)	2 (Opt)	Kritis
24	4 (VH)	3 (H)	Kritis
25	4 (VH)	4 (VH)	Kritis Ekstrem

Tabel matriks di atas menjadi acuan navigasi bagi agen, di mana State 13 ditetapkan sebagai target kondisi ideal (pH Optimal dan EC Optimal).

3.4.2 Definisi Ruang Aksi (Action-Space)

Efektivitas agen Q-Learning tidak hanya bergantung pada kemampuan persepsi (*State*), tetapi juga pada granularitas kendali yang dimilikinya. Mengingat karakteristik pH yang bersifat logaritmik dan sensitif, penggunaan durasi dosing yang seragam (*fixed duration*) berisiko menyebabkan osilasi di sekitar titik *setpoint*. Oleh karena itu, Ruang Aksi (*Action-Space*) pada penelitian ini dirancang dengan pendekatan *Multi-Level Dosing* untuk memberikan respons proporsional terhadap tingkat keparahan *error* yang teridentifikasi di ruang keadaan.

Strategi ini membagi intervensi aktuator menjadi dua kategori intensitas:

1. *Fine-Tuning Action* (t_{short}): Diterapkan saat sistem berada pada zona 'Transisi' atau 'Sub-Optimal'. Aksi ini memberikan koreksi halus untuk mendekati target secara perlahan (*soft landing*) tanpa memicu lonjakan nilai yang drastis.
2. *Coarse-Tuning Action* (t_{long}): Diterapkan saat sistem berada pada zona 'Kritis'. Aksi ini memberikan koreksi agresif untuk segera mengembalikan parameter fisika air ke wilayah aman sebelum tanaman mengalami stres permanen.

Ruang aksi didefinisikan sebagai himpunan diskrit yang terdiri dari 9 kemungkinan keputusan, Aksi-aksi ini mengendalikan tiga kelompok aktuator, pompa korektor pH (Asam/Basa), pompa nutrisi A, B (untuk menaikkan EC) dan pompa air baku (untuk menurunkan EC melalui dilusi). Definisi lengkap setiap aksi beserta dampak fisiknya terhadap lingkungan disajikan pada Tabel 3.4.

Tabel 3. 4 Definisi Ruang Aksi dan Durasi Dosing

Idx	Kode Aksi	Aktuator Target	Durasi	Dampak Fisik pada Lingkungan (State)
0	Idle	None	0 s	Mempertahankan kondisi saat ini (No Change)
1	pH Up Short	Pompa pH Up	t_{short}	Menaikkan nilai pH (Koreksi Halus)
2	pH Up Long	Pompa pH Up	t_{long}	Menaikkan nilai pH (Koreksi Kasar)
3	pH Down Short	Pompa pH Down	t_{short}	Menurunkan nilai pH (Koreksi Halus)
4	pH Down Long	Pompa pH Down	t_{long}	Menurunkan nilai pH (Koreksi Kasar)
5	Nutrisi Short	Pompa Nutrisi	t_{short}	Menaikkan nilai EC (Koreksi Halus)
6	Nutrisi Long	Pompa Nutrisi	t_{long}	Menaikkan nilai EC (Koreksi Kasar)
7	Air Baku Short	Pompa Air	t_{short}	Menurunkan nilai EC (Dilusi Halus)
8	Air Baku Long	Pompa Air	t_{long}	Menurunkan nilai EC (Dilusi Halus)

3.4.3 Struktur Tabel Pengetahuan (Q-Table)

Mengacu pada Matriks Pemetaan Ruang Keadaan (Tabel 3.3) dan Definisi Ruang Aksi (Tabel 3.4), struktur memori agen dibentuk sebagai matriks Q-Table berdimensi 25 × 9. Dimensi ini terbentuk secara matematis dari total 25 *State* unik (baris) dan 9 *Action* diskrit (kolom).

Setiap sel dalam matriks ini menyimpan nilai *Q-Value* yang akan diperbarui secara iteratif selama proses pembelajaran. Pada tahap inisialisasi awal, seluruh elemen matriks diatur bernilai 0.00 yang menandakan agen belum memiliki

pengetahuan awal. Struktur visual Q-Table yang digunakan disajikan pada Tabel 3.5.

Tabel 3.5 Struktur Matriks Q-Table (25 × 9)

State (S)	A0 (Idle)	A1 (pH Up S)	A2 (pH Up L)	A3 (pH Dn S)	A4 (pH Dn L)	A5 (Nut S)	A6 (Nut L)	A7 (Air S)	A8 (Air L)
State 1	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
State 2	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
State 13	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
State 25	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00

Secara komputasional, matriks Q-Table berukuran 25 baris × 9 kolom ini merepresentasikan kapasitas memori agen yang mencakup 225 pasangan Keadaan-Aksi (*State-Action Pairs*). Pada tahap inisialisasi ($t = 0$), seluruh sel matriks diatur bernilai 0.00. Kondisi ini dikenal sebagai Tabula Rasa, di mana agen belum memiliki pengetahuan apa pun tentang dinamika sistem hidroponik.

Setiap sel nantinya tidak sekadar menyimpan nilai hadiah sesaat (r_t), melainkan mengakumulasi *Expected Future Reward* (harapan imbalan jangka panjang). Nilai ini akan diperbarui secara iteratif menggunakan Persamaan Bellman setiap kali agen melakukan aksi, sehingga angka yang terbentuk di dalam tabel merupakan representasi numerik dari 'pengalaman' agen dalam menjaga stabilitas pH dan EC.

3.4.4 Perancangan Fungsi Hadiah (Reward Function)

Fungsi Hadiah (*Reward Function*) dirancang sebagai mekanisme navigasi utama untuk menuntun agen menemukan kebijakan kontrol optimal. Penelitian ini menerapkan strategi Insentif Berbasis Zona (*Zone-Based Incentive*), di mana pemberian nilai hadiah ditentukan sepenuhnya oleh posisi akurasi agen terhadap target (*State Goal*).

Dalam strategi ini, prioritas sistem adalah pencapaian stabilitas parameter fisika air. Agen didorong untuk melakukan tindakan koreksi berdasarkan tingkat urgensi kondisi lingkungan yang terdeteksi.

Secara matematis, total hadiah pada setiap langkah waktu diformulasikan menggunakan fungsi sepotong-sepotong (*piecewise function*) yang memetakan kategori zona keadaan (*State Zone*) ke nilai skalar tertentu, sebagai berikut:

$$R_{(t+1)} = R_{(zona)}(S_{t+1})$$

Komponen R_{zona} didefinisikan sebagai fungsi sepotong-sepotong (*piecewise*) berikut:

$$R_{(\text{zona})(S)} = \begin{cases} +50, \text{jika } S \in \mathcal{S}_{(\text{target})} & (\text{Target/Goal}) \\ +10, \text{jika } S \in \mathcal{S}_{(\text{sub})} & (\text{Sub-Optimal}) \\ -5, \text{jika } S \in \mathcal{S}_{(\text{trans})} & (\text{Transisi}) \\ -80, \text{jika } S \in \mathcal{S}_{(\text{crit})} & (\text{Kritis}) \\ -120, \text{jika } S \in \mathcal{S}_{(\text{extreme})} & (\text{Kritis Ekstrem}) \end{cases}$$

Rasionalisasi nilai hadiah tersebut adalah:

- $+50$ (Target) hadiah terbesar agar agen memprioritaskan kondisi State 13.
- $+10$ (Safety Net) mencegah agen melakukan aksi koreksi berlebihan (*Overshoot*) saat sudah dekat target.
- -5 (Warning) peringatan dini agar agen melakukan koreksi halus (*fine-tuning*).
- -80 (Kritis) hukuman berat saat salah satu parameter masuk zona berbahaya.
- -120 (Ekstrem) Hukuman maksimal saat pH dan EC rusak bersamaan (State 1, 5, 21, 25). Perbedaan dengan nilai -80 memaksa agen untuk tidak pasrah dan segera memperbaiki minimal satu parameter.

Tabel 3.6 Distribusi Nilai Reward Berdasarkan Zona State

State ID	Status Zona (Ref. Tabel 3.3)	Reward (R_{zona})	Keterangan Logika

1	Kritis Ekstrem	-120	Bahaya Fatal (pH & EC Buruk)
2	Kritis	-80	Bahaya (Salah satu Buruk)
3	Kritis	-80	Bahaya (Salah satu Buruk)
4	Kritis	-80	Bahaya (Salah satu Buruk)
5	Kritis Ekstrem	-120	Bahaya Fatal (pH & EC Buruk)
6	Kritis	-80	Bahaya (Salah satu Buruk)
7	Transisi	-5	Peringatan Dini
8	Sub-Optimal	+10	Zona Aman (Safety Net)
9	Transisi	-5	Peringatan Dini
10	Kritis	-80	Bahaya (Salah satu Buruk)
11	Kritis	-80	Bahaya (Salah satu Buruk)
12	Sub-Optimal	+10	Zona Aman (Safety Net)
13	Target (Goal)	+50	Kondisi Ekuilibrium
14	Sub-Optimal	+10	Zona Aman (Safety Net)
15	Kritis	-80	Bahaya (Salah satu Buruk)
16	Kritis	-80	Bahaya (Salah satu Buruk)
17	Transisi	-5	Peringatan Dini
18	Sub-Optimal	+10	Zona Aman (Safety Net)
19	Transisi	-5	Peringatan Dini
20	Kritis	-80	Bahaya (Salah satu Buruk)
21	Kritis Ekstrem	-120	Bahaya Fatal (pH & EC Buruk)
22	Kritis	-80	Bahaya (Salah satu Buruk)
23	Kritis	-80	Bahaya (Salah satu Buruk)
24	Kritis	-80	Bahaya (Salah satu Buruk)
25	Kritis Ekstrem	-120	Bahaya Fatal (pH & EC Buruk)

3.4.5 Logika Algoritma dan Eksekusi Aksi

Integrasi antara logika agen cerdas (Raspberry Pi) dan eksekusi fisik (ESP32) divisualisasikan dalam diagram alir sistem pada **Gambar 3.3**. Visualisasi ini menggunakan alur *Swimlane* untuk memisahkan beban kerja *Node Kendali* dan *Node Aktuator* dalam arsitektur terdistribusi *closed-loop*.

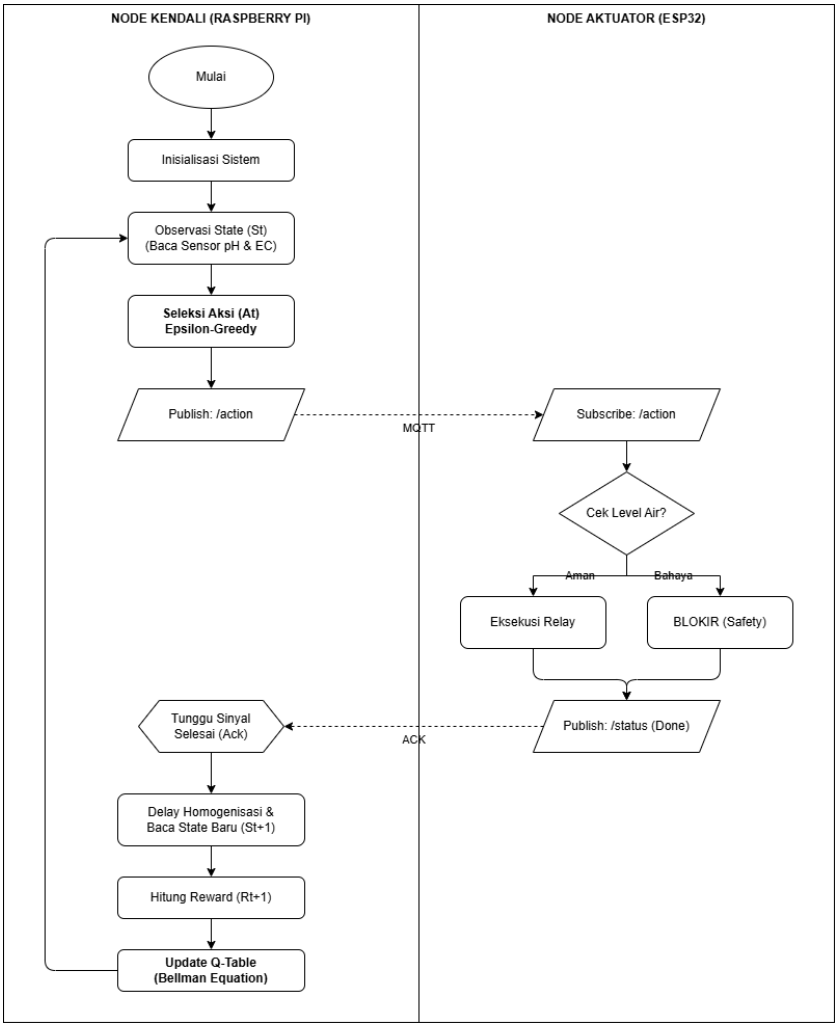

Gambar 3.3 Diagram Alir Logika Agen Q-Learning

Berdasarkan alur pada Gambar 3.3, mekanisme pengendalian dibagi menjadi empat fase sekuensial:

1. Fase Observasi (*Sensing & Mapping*) diklus dimulai dengan inisialisasi sistem. Agen mengakuisisi data *real-time* dari sensor pH dan EC. Data mentah yang bersifat kontinu ini kemudian didiskritisasi menjadi indeks *State* (S_t) sesuai aturan pemetaan pada Tabel 3.3. Langkah ini krusial untuk

menyederhanakan kompleksitas lingkungan menjadi format yang dapat diproses oleh *Q-Table*.

2. Fase Keputusan (*Decision Making*): Berdasarkan *State* yang teridentifikasi, agen menyeleksi Aksi (A_t) dari himpunan ruang aksi yang tersedia (Idx 0–8). Algoritma memprioritaskan aksi dengan *Q-Value* tertinggi untuk mendekatkan sistem ke target. Krusial pada tahap ini, indeks aksi yang terpilih dipetakan kembali ke variabel durasi yang sesuai (t_{short} atau t_{long}) merujuk pada Tabel 3.4. Nilai durasi hasil pemetaan inilah yang kemudian dikemas dalam format *payload* protokol MQTT dan dikirimkan ke Node Aktuator sebagai perintah kerja.
3. Fase Eksekusi dan Proteksi (*Actuation & Safety*): Node aktuator (ESP32) menerima paket data berisi nilai durasi numerik (dalam milidetik) yang dikirimkan oleh agen. Sebelum eksekusi, sistem menjalankan prosedur *Safety Interlock* dengan memeriksa sensor *water level*.
    - Jika level air Aman: *Relay* diaktifkan secara presisi sesuai durasi waktu (t) yang diterima dalam paket data.
    - Jika level air Bahaya: Sistem melakukan *Override* (memblokir aksi) untuk mencegah kerusakan pompa akibat *dry running*.
    - Status selesai : Baik dalam kondisi aman maupun terblokir, node aktuator mengirimkan sinyal balik (*Acknowledgment*) ke agen untuk menandakan transaksi selesai.
4. Fase Evaluasi dan Pembelajaran (*Update Rule*) setelah aksi dieksekusi, sistem memberikan jeda waktu (*delay*) agar larutan tercampur homogen sebelum membaca kondisi terbaru (S_{t+1}). Agen kemudian menghitung nilai *Reward* (R_{t+1}) berdasarkan fungsi tujuan yang telah ditetapkan. Siklus ditutup dengan pembaruan nilai matriks *Q-Table* menggunakan persamaan Bellman, yang memungkinkan agen untuk semakin "cerdas" dan presisi seiring bertambahnya iterasi.

3.5 Skenario Pengujian

Rangkaian pengujian sistem dirancang untuk memvalidasi performa agen Q-Learning dalam tiga aspek fundamental: kemampuan pembelajaran (*learning*

capability), karakteristik respon transien (*transient response*), dan ketahanan terhadap gangguan (*robustness*). Data hasil pengujian akan dianalisis secara kuantitatif untuk membuktikan efektivitas algoritma dalam menjaga stabilitas pH dan EC sesuai batasan masalah yang ditetapkan.

3.5.1 Pengujian Fase Pelatihan (Training Convergence)

Pengujian ini bertujuan memverifikasi keberhasilan proses pembelajaran agen dalam menemukan kebijakan optimal (*optimal policy*) dari kondisi *null-knowledge* (Tabula Rasa).

- Skenario: Agen dilatih dalam simulasi lingkungan (*environment*) selama 500 episode. Pada setiap awal episode, nilai *State* diinisialisasi secara acak pada zona kritis untuk memaksa agen melakukan eksplorasi jalur keputusan menuju target (State 13).
- Parameter yang Diukur:
  - Akumulasi *reward* (*Total Reward*) jumlah poin bersih yang dikumpulkan agen dalam satu episode lengkap
  - Jumlah langkah (*Steps per Episode*) banyaknya iterasi aksi yang dibutuhkan agen untuk mencapai target dari kondisi awal.
- Target Keberhasilan: Proses pelatihan dinyatakan berhasil jika grafik *Total Reward* menunjukkan tren peningkatan logaritmik yang kemudian stabil (*steady-state*) pada nilai positif maksimum. Secara simultan, grafik *Steps* harus menunjukkan tren eksponensial menurun, yang membuktikan bahwa agen mampu mencapai target dengan jalur eksekusi yang paling efisien (langkah minimal).

3.5.2 Pengujian Respon Kendali (Control Response)

Setelah agen dinyatakan konvergen, pengujian ini dilakukan untuk mengevaluasi kualitas respon transien sistem dalam menangani kondisi ekstrem. Fokus utama pengujian adalah mengukur kecepatan (*speed*) dan ketepatan (*accuracy*) agen dalam mengembalikan parameter air ke titik ekuilibrium.

- Skenario: Sistem diinisialisasi secara paksa pada kondisi gangguan berat (pH 4.0 atau EC 800 µS/cm). Agen diaktifkan untuk melakukan aksi koreksi otonom menuju *setpoint* (pH 6.0 dan EC 1200 µS/cm).

Parameter yang Diukur:

1. *Settling Time* (t_s): Didefinisikan sebagai durasi waktu yang dibutuhkan respons sistem untuk masuk dan bertahan (*holding*) di dalam pita toleransi target (± 0.2pH dan ± 100 µS/cm) selama minimal 60 detik berturut-turut. Jika nilai keluar dari pita toleransi sebelum 60 detik, waktu perhitungan *settling time* akan di-reset.
2. *Maximum Overshoot* (M_p): Diukur sebagai persentase atau nilai deviasi maksimum yang melampaui *setpoint* sebelum sistem mencapai kondisi *steady-state*. Target optimasi agen adalah meminimalkan nilai ini untuk mencegah *shock* pada akar tanaman.

3.5.3 Pengujian Gangguan (Disturbance Test)

Pengujian ini bertujuan memvalidasi *robustness* sistem dalam mempertahankan kestabilan parameter (pH dan EC) saat terjadi perubahan lingkungan eksternal yang tidak terduga, seperti pengisian ulang air baku atau hujan.

- Skenario Gangguan Langkah (*Step Disturbance*): Saat sistem telah mencapai kondisi *steady-state* pada titik kerja (pH 6.0 dan EC 1200 µS/cm), diberikan gangguan eksternal berupa injeksi air baku (pH $\approx$ 7.0, EC $\approx$ 0 µS/cm) sebanyak 10% dari volume total cairan secara instan. Gangguan ini mensimulasikan efek dilusi mendadak yang memaksa nilai EC turun drastis dan pH berubah menjauhi *setpoint*.
- Parameter Ukur:
    1. *Maximum Deviation* (Δ_{max}): Selisih terjauh antara nilai sensor dengan *setpoint* sesaat setelah gangguan diberikan. Parameter ini

mengukur seberapa besar dampak gangguan terhadap sistem sebelum agen bereaksi.

2. *Recovery Time* (t_{rec}): Durasi waktu yang dibutuhkan agen untuk mendeteksi perubahan *State*, mengambil aksi kompensasi (misal: *dosing* nutrisi), dan mengembalikan parameter air kembali ke zona toleransi target ($\pm$ 2% dari *setpoint*). Semakin singkat waktu pemulihan, semakin responsif performa agen Q-Learning

BAB IV

Daftar Referensi

Abdulkadir, A., Kabir, M. T., Abdulkareem, H. A., & Abdullahi, Z. (2025). Adaptive Q-Learning-Based Radio Resource Management Optimization in 5G and Beyond Heterogeneous-Homogeneous Networks: A Comprehensive Review. *Asian Journal of Science, Technology, Engineering, and Art*, *3*(1), 137–154. https://doi.org/10.58578/ajstea.v3i1.4578

Agustian, I., Prayoga, B. I., Santosa, H., Daratha, N., & Faurina, R. (2022). NFT Hydroponic Control Using Mamdani Fuzzy Inference System. *Journal of Robotics and Control (JRC)*, *3*(3), 374–383. https://doi.org/10.18196/jrc.v3i3.14714

Bashabsheh, M. (2024). Autonomous Robotic Systems with Artificial Intelligence Technology Using a Deep Q Network-Based Approach for Goal-Oriented 2D Arm Control. *Journal of Robotics and Control (JRC)*, *5*(6), 1872–1887. https://doi.org/10.18196/jrc.v5i6.23850

Cai, Y., Zhao, Z., Guo, W., Xu, H., Teng, Y., Han, X., Zhao, Q., & Wang, L. (2025). Smart Nutrient Solution Temperature Control System for Oversummering Lettuce Cultivation Based on Adaptive Dung Beetle Optimizer-Fuzzy PID. *Applied Sciences (Switzerland)*, *15*(10). https://doi.org/10.3390/app15105381

Catota-Ocapana, P., Minaya-Andino, C., Astudillo, P., & Pichoasamin, D. (2025). Smart Control Models Used for Nutrient Management in Hydroponic Crops: A Systematic Review. In *IEEE Access* (Vol. 13, pp. 13070–13087). Institute of Electrical and Electronics Engineers Inc. https://doi.org/10.1109/ACCESS.2025.3526171

Dakshinamurthy, S., & Mohan, B. (2024). *Adaptive Control of Smart Hydroponic Systems Using Reinforcement Learning: A Comparative Study with PID*. https://doi.org/https://doi.org/10.36948/ijfmr.2025.v07i03.42424

Hutauruk, A. R. (2025). Kendali Otomatis Tingkat Ketinggian Air Dan Nutrisi Pada Hidroponik Menggunakan Metode Finite State Machine. *Jurnal Informatika Dan Teknik Elektro Terapan*, *13*(1). https://doi.org/10.23960/jitet.v13i1.6044

Jain, S., & Kaur, M. (2024). Design and Implementation of an IoT-based automated EC and pH Control System in an NFT-based Hydroponic Farm. *Engineering, Technology and Applied Science Research*, *14*(1), 13078–13081. https://doi.org/10.48084/etasr.6393

Kurniawan, L. A., & Amirullah, A. (2021). Monitoring and Controlling of pH Levels and Plant Nutrition Supplied by Standalone Photovoltaic in a Greenhouse Hydroponic System using Arduino Uno. *Jurnal Iptek*, *25*, 69–76.

Lu, Y., Gong, M., Li, J., & Ma, J. (2023). Optimizing Controlled Environmental Agriculture for Strawberry Cultivation Using RL-Informer Model. *Agronomy*, *13*(8). https://doi.org/10.3390/agronomy13082057

Marković, M., Galić, V., Težak, V., Ravlić, M., Barač, Ž., Jug, I., & Galić, L. (2025). The Irrigation Water pH Has a Dominant Impact on the Growth and Stress Markers of Bigleaf Hydrangea. *Applied Sciences (Switzerland)*, *15*(16). https://doi.org/10.3390/app15168773

Morcego, B., Yin, W., Boersma, S., van Henten, E., Puig, V., & Sun, C. (2023). Reinforcement Learning versus Model Predictive Control on greenhouse climate control. *Computers and Electronics in Agriculture*, *215*. https://doi.org/10.1016/j.compag.2023.108372

Munaf, A., & Almusawi, A. R. J. (2024). Integration of Q-Learning and PID Controller for Mobile Robots Trajectory Tracking in Unknown Environments. *Journal Europeen Des Systemes Automatises*, *57*(4), 1023–1033. https://doi.org/10.18280/jesa.570410

Panjapornpon, C., Chinchalongporn, P., Bardeeniz, S., Makkayatorn, R., & Wongpunnawat, W. (2022). Reinforcement Learning Control with Deep Deterministic Policy Gradient Algorithm for Multivariable pH Process. *Processes*, *10*(12). https://doi.org/10.3390/pr10122514

Ridwan, A. M., Milah, A. S., Kamelia, L., & Renaldi Gunawan, M. R. (2025). Sistem Kendali Fuzzy Logic untuk Kestabilan pH dan EC Nutrisi Pada Hidroponik. *Jurnal Teknologi Elektro*, *15*(3), 152. https://doi.org/10.22441/jte.2024.v15i3.002

Shareef, U., Rehman, A. U., & Ahmad, R. (2024). A Systematic Literature Review on Parameters Optimization for Smart Hydroponic Systems. In *AI (Switzerland)* (Vol. 5, Issue 3, pp. 1517–1533). Multidisciplinary Digital Publishing Institute (MDPI). https://doi.org/10.3390/ai5030073

Su, Z. (2025). *Application of Q-learning in Autonomous Robot Obstacle Avoidance* (pp. 366–375). https://doi.org/10.2991/978-94-6463-823-3_36

Sulaiman, H., Yusof, A. A., & Mohamed Nor, M. K. (2025). Automated Hydroponic Nutrient Dosing System: A Scoping Review of pH and Electrical Conductivity Dosing Frameworks. In *AgriEngineering* (Vol. 7, Issue 2). Multidisciplinary Digital Publishing Institute (MDPI). https://doi.org/10.3390/agriengineering7020043

Tatas, K., Al-Zoubi, A., Christofides, N., Zannettis, C., Chrysostomou, M., Panteli, S., & Antoniou, A. (2022). Reliable IoT-Based Monitoring and Control of Hydroponic Systems. *Technologies*, *10*(1). https://doi.org/10.3390/technologies10010026

Wang, Y., Liu, J., Li, R., Suo, X., & Lu, E. (2022). Application of PSO-BPNN-PID Controller in Nutrient Solution EC Precise Control System: Applied Research. *Sensors*, *22*(15). https://doi.org/10.3390/s22155515